

Codebook

Establecimientos de Nivel Diversificado — Guatemala

Proyecto: Project_01_Data_Science Fuente de los datos: MINEDUC — Buscador de Establecimientos (http://www.mineduc.gob.gt/BUSCAESTABLECIMIENTO_GE/) Método de obtencion: Web scraping por departamento (22 páginas HTML) con scripts/web_scrapping/scrapping_sat_csv.py, consolidado en data/raw/consolidado_diversificado.csv Fecha de extraccion: 2026-07-21
Notebook de limpieza: notebooks/data_cleaning.ipynb Archivo limpio final: data/clean/establecimientos_diversificado_limpio.csv

1. Resumen del pipeline

1. Extracción (scraping): scripts/web_scrapping/scrapping_sat_csv.py recorre las 22 páginas HTML de departamentos guardadas en data/paginas_departamentos/ y consolida los establecimientos de nivel DIVERSIFICADO en data/raw/consolidado_diversificado.csv.
 2. Diagnóstico: conteo de registros/variables, tipos de dato, faltantes, valores únicos, duplicados exactos, valores fuera de dominio y formatos inconsistentes (notebooks/data_cleaning.ipynb, secciones 3.a-3.h).
 3. Plan de limpieza: tabla variable por variable con problema, regla de corrección, justificación y riesgos, documentada antes de tocar los datos.
 4. Implementación: normalización de texto, unificación de categorías, tipado correcto, separación de teléfonos, marcado (no eliminación) de duplicados.
 5. Validación automática: batería de pruebas (assert) sobre el conjunto limpio.
 6. Exportación: tres archivos en data/clean/:
 - establecimientos_diversificado_limpio.csv — datos limpios
 - registro_transformaciones.csv — log de cada transformación aplicada
 - informe_calidad_antes_despues.csv — métricas de calidad antes/después
-

2. Variables originales (crudo -> limpio)

#	Variable (cruda)	Tipo pandas crudo	Variable en el limpio	Tipo fi- nal	Descrip- ción	Do- minio / formato
1	CODIGO	object	CODIGO	texto	Identificador único del establecimiento	XX-XX-XXXX-XX (100% de filas cumple el formato)
2	DISTRITO	object	DISTRITO	texto	Código del distrito escolar de supervisión	Dos esquemas válidos coexisten: XX-XXX y XX-XX-XXXX; códigos truncados → NA
3	DEPARTAMENTO	object	DEPARTAMENTO	category	Departamento del establecimiento	22 departamentos oficiales de Guatemala (ver §3)
4	MUNICIPIO	object	MUNICIPIO	category	Municipio del establecimiento	330 municipios observados tras la limpieza
5	ESTABLECIMIENTO	object	ESTABLECIMIENTO	texto	Nombre del establecimiento	Texto libre, espacios normalizados
6	DEPARTAMENTO	object	DEPARTAMENTO	category	Código del departamento	22 departamentos oficiales de Guatemala (ver §3)
7	MUNICIPIO	object	MUNICIPIO	category	Código del municipio	330 municipios observados tras la limpieza
8	ESTABLECIMIENTO	object	ESTABLECIMIENTO	texto	Nombre del establecimiento	Texto libre, espacios normalizados
9	DEPARTAMENTO	object	DEPARTAMENTO	category	Código del departamento	22 departamentos oficiales de Guatemala (ver §3)
10	MUNICIPIO	object	MUNICIPIO	category	Código del municipio	330 municipios observados tras la limpieza
11	ESTABLECIMIENTO	object	ESTABLECIMIENTO	texto	Nombre del establecimiento	Texto libre, espacios normalizados
12	DEPARTAMENTO	object	DEPARTAMENTO	category	Código del departamento	22 departamentos oficiales de Guatemala (ver §3)
13	MUNICIPIO	object	MUNICIPIO	category	Código del municipio	330 municipios observados tras la limpieza
14	ESTABLECIMIENTO	object	ESTABLECIMIENTO	texto	Nombre del establecimiento	Texto libre, espacios normalizados
15	DEPARTAMENTO	object	DEPARTAMENTO	category	Código del departamento	22 departamentos oficiales de Guatemala (ver §3)
16	MUNICIPIO	object	MUNICIPIO	category	Código del municipio	330 municipios observados tras la limpieza
17	ESTABLECIMIENTO	object	ESTABLECIMIENTO	texto	Nombre del establecimiento	Texto libre, espacios normalizados
18	DEPARTAMENTO	object	DEPARTAMENTO	category	Código del departamento	22 departamentos oficiales de Guatemala (ver §3)
19	MUNICIPIO	object	MUNICIPIO	category	Código del municipio	330 municipios observados tras la limpieza
20	ESTABLECIMIENTO	object	ESTABLECIMIENTO	texto	Nombre del establecimiento	Texto libre, espacios normalizados
21	DEPARTAMENTO	object	DEPARTAMENTO	category	Código del departamento	22 departamentos oficiales de Guatemala (ver §3)
22	MUNICIPIO	object	MUNICIPIO	category	Código del municipio	330 municipios observados tras la limpieza
23	ESTABLECIMIENTO	object	ESTABLECIMIENTO	texto	Nombre del establecimiento	Texto libre, espacios normalizados
24	DEPARTAMENTO	object	DEPARTAMENTO	category	Código del departamento	22 departamentos oficiales de Guatemala (ver §3)
25	MUNICIPIO	object	MUNICIPIO	category	Código del municipio	330 municipios observados tras la limpieza
26	ESTABLECIMIENTO	object	ESTABLECIMIENTO	texto	Nombre del establecimiento	Texto libre, espacios normalizados
27	DEPARTAMENTO	object	DEPARTAMENTO	category	Código del departamento	22 departamentos oficiales de Guatemala (ver §3)
28	MUNICIPIO	object	MUNICIPIO	category	Código del municipio	330 municipios observados tras la limpieza
29	ESTABLECIMIENTO	object	ESTABLECIMIENTO	texto	Nombre del establecimiento	Texto libre, espacios normalizados
30	DEPARTAMENTO	object	DEPARTAMENTO	category	Código del departamento	22 departamentos oficiales de Guatemala (ver §3)
31	MUNICIPIO	object	MUNICIPIO	category	Código del municipio	330 municipios observados tras la limpieza
32	ESTABLECIMIENTO	object	ESTABLECIMIENTO	texto	Nombre del establecimiento	Texto libre, espacios normalizados
33	DEPARTAMENTO	object	DEPARTAMENTO	category	Código del departamento	22 departamentos oficiales de Guatemala (ver §3)
34	MUNICIPIO	object	MUNICIPIO	category	Código del municipio	330 municipios observados tras la limpieza
35	ESTABLECIMIENTO	object	ESTABLECIMIENTO	texto	Nombre del establecimiento	Texto libre, espacios normalizados
36	DEPARTAMENTO	object	DEPARTAMENTO	category	Código del departamento	22 departamentos oficiales de Guatemala (ver §3)
37	MUNICIPIO	object	MUNICIPIO	category	Código del municipio	330 municipios observados tras la limpieza
38	ESTABLECIMIENTO	object	ESTABLECIMIENTO	texto	Nombre del establecimiento	Texto libre, espacios normalizados
39	DEPARTAMENTO	object	DEPARTAMENTO	category	Código del departamento	22 departamentos oficiales de Guatemala (ver §3)
40	MUNICIPIO	object	MUNICIPIO	category	Código del municipio	330 municipios observados tras la limpieza
41	ESTABLECIMIENTO	object	ESTABLECIMIENTO	texto	Nombre del establecimiento	Texto libre, espacios normalizados
42	DEPARTAMENTO	object	DEPARTAMENTO	category	Código del departamento	22 departamentos oficiales de Guatemala (ver §3)
43	MUNICIPIO	object	MUNICIPIO	category	Código del municipio	330 municipios observados tras la limpieza
44	ESTABLECIMIENTO	object	ESTABLECIMIENTO	texto	Nombre del establecimiento	Texto libre, espacios normalizados
45	DEPARTAMENTO	object	DEPARTAMENTO	category	Código del departamento	22 departamentos oficiales de Guatemala (ver §3)
46	MUNICIPIO	object	MUNICIPIO	category	Código del municipio	330 municipios observados tras la limpieza
47	ESTABLECIMIENTO	object	ESTABLECIMIENTO	texto	Nombre del establecimiento	Texto libre, espacios normalizados
48	DEPARTAMENTO	object	DEPARTAMENTO	category	Código del departamento	22 departamentos oficiales de Guatemala (ver §3)
49	MUNICIPIO	object	MUNICIPIO	category	Código del municipio	330 municipios observados tras la limpieza
50	ESTABLECIMIENTO	object	ESTABLECIMIENTO	texto	Nombre del establecimiento	Texto libre, espacios normalizados

3. Variables derivadas (creadas durante la limpieza)

Variable	Tipo	Descripción	Regla de generación	Cobertura
ZONA_CIUADAD_GUATEMALA	texto (dígitos)	Número de zona de la ciudad de Guatemala, cuando aplica	Extraída de MUNICIPIO cuando el valor original era "ZONA n" (antes clasificado bajo el pseudo-departamento "CIUDAD CAPITAL")	Solo establecimientos de la ciudad de Guatemala (9,707 NA / 11,868)
TELEFONO_PRINCIPAL	texto (7-8 dígitos)	Primer número telefónico válido extraído del campo original TELEFONO	Regex \d{7,8} sobre el campo crudo; primera coincidencia	973 NA
TELEFONO_SECUNDARIO	texto (dígitos, separados por ;)	Número(s) telefónicos adicionales, cuando el campo original traía más de uno	Coincidencias adicionales del mismo regex	11,698 NA (solo aplica a registros con 2+ números)
TELEFONO_VALIDO	booleano	True si TELEFONO_PRINCIPAL tiene exactamente 8 dígitos (formato guatemalteco vigente)	len(TELEFONO_PRINCIPAL) == 8	Sin NA
DUPLICADO_EXACTO_SIN_CODIGO	booleano	True si la fila es idéntica a otra en todas las columnas excepto CODIGO	duplicated(subset=todos menos CODIGO, keep=False)	Sin NA — no se elimina automáticamente, requiere revisión manual
POSIBLE_DUPLICADO_PARCIAL	booleano	True si el nombre del establecimiento es muy similar (>0.90)	difflib.SequenceMatcher sobre nombre normalizado (sin tildes/mayúsculas). agrupado	Sin NA — no se fusiona automáticamente, requiere revisión manual

4. Transformaciones aplicadas por variable

Variable	Problema detectado	Transformación aplicada	Justificación	Riesgo documentado
CODIGO	Ninguno relevante (formato consistente en 100%)	Se mantiene como texto (no numérico)	Evita perder ceros a la izquierda	Ninguno
DISTRITO	Dos esquemas de código (XX-XXX vs XX-XX-XXXX) + ~70 códigos truncados ("01-")	Truncados → NA; los dos formatos válidos se conservan tal cual	Un código incompleto no identifica un distrito real; inventar el segmento sería fabricar datos	Se pierde el dato en ~70 filas (0.6%) en vez de adivinarlo
DEPARTAMENTO	23 categorías en vez de 22 oficiales; "CIUDAD CAPITAL" no es un departamento	"CIUDAD CAPITAL" → "GUATEMALA"	Catálogo oficial (INE/MINEDUC) tiene 22 departamentos	Se pierde la distinción capital/resto;
MUNICIPIO	Para ex-CIUDAD CAPITAL, traía zona ("zona 1") en vez de municipio	MUNICIPIO = "GUATEMALA" + nueva variación de ZONA_CIUDAD_GUATEMALA	El municipio real es Guatemala; la zona se preserva como dato derivado	Si se necesitara zona para todos los municipios, la variable queda mayormente vacía
ESTABLECIMIENTO	Espacios dobles/múltiples; ~5 NA; posibles duplicados parciales de nombre	Normalización de espacios; similitud de cadenas para marcar (no fusionar)	Los espacios no aportan información; nombres con comillas son válidos en español	Umbral bajo generaría falsos positivos en nombres genéricos

El detalle fila por fila de cada transformación (con conteo exacto de registros afectados) está en `data/clean/registro_transformaciones.csv`.

5. Catálogo de dominios controlados

DEPARTAMENTO (22 valores oficiales): ALTA VERAPAZ, BAJA VERAPAZ, CHIMALTENANGO, CHIQUIMULA, EL PROGRESO, ESCUINTLA, GUATEMALA, HUEHUETENANGO, IZABAL, JALAPA, JUTIAPA, PETEN, QUETZALTENANGO, QUICHE, RETALHULEU, SACATEPEQUEZ, SAN MARCOS, SANTA ROSA, SOLOLA, SUCHITEPEQUEZ, TOTONICAPAN, ZACAPA

SECTOR: COOPERATIVA, MUNICIPAL, OFICIAL, PRIVADO

AREA: RURAL, URBANA, SIN ESPECIFICAR

STATUS: ABIERTA, CERRADA DEFINITIVAMENTE, CERRADA TEMPORALMENTE, TEMPORAL NOMBRAMIENTO, TEMPORAL TITULOS

MODALIDAD: BILINGUE, MONOLINGUE

JORNADA: DOBLE, INTERMEDIA, MATUTINA, NOCTURNA, SIN JORNADA, VESPERTINA

PLAN:** A DISTANCIA, DIARIO(REGULAR), DOMINICAL, FIN DE SEMANA, INTERCALADO, IRREGULAR, MIXTO, SABATINO, SEMIPRESENCIAL, SEMIPRESENCIAL (DOS DÍAS A LA SEMANA), SEMIPRESENCIAL (FIN DE SEMANA), SEMIPRESENCIAL (UN DÍA A LA SEMANA), VIRTUAL A DISTANCIA

MUNICIPIO: sin catálogo oficial embebido en el proyecto (330 valores observados tras la limpieza). Se validó ausencia de errores tipográficos mediante similitud de cadenas (>0.85) dentro de cada departamento; no se encontraron variantes, salvo el caso ya corregido de "ZONA n". **Limitación conocida:** el catálogo de referencia es el conjunto de valores observados, no una fuente oficial externa.

6. Validaciones automáticas aplicadas al conjunto limpio

- CODIGO es único (sin duplicados exactos por identificador).
- Ninguna columna de texto tiene espacios al inicio/fin.
- TELEFONO_PRINCIPAL contiene solo 7-8 dígitos numéricos (o NA).
- DEPARTAMENTO tiene exactamente los 22 departamentos oficiales.
- MUNICIPIO ya no contiene valores tipo "ZONA n".
- Todas las variables categóricas están tipadas como category.
- COD_DEPARTAMENTO_ORIGEN es texto de 2 dígitos.

- No hay categorías duplicadas por diferencias de mayúsculas/minúsculas o espacios en las variables de dominio controlado.

7. Informe de calidad — antes vs. despues

Metrica	Antes	Despues
Registros	11,868	11,868
Variables	18	23
Variables con formato inconsistente corregido	3	0
Variables con tipo incorrecto corregido	2	0
Categorías inconsistentes unificadas	1	0
Duplicados exactos (fila completa)	0	0 (por unicidad de CODIGO)
Duplicados exactos ver informe_calidad_antes_marcados en DUPLICADO_EXACTO_SIN_CODIGO, cluyendo CODIGO	no evaluado	no eliminados
Posibles duplicados parciales (nombre similar)	no evaluado	marcados en POSIBLE_DUPLICADO_PARCIAL, no fusionados

Nota sobre el aumento de valores faltantes tras la limpieza: el número de celdas NA sube, no porque se pierda información, sino porque (1) se destaparon faltantes disfrazados como texto ("--", "SIN DATO") que antes contaban como “presentes”, y (2) se crearon variables derivadas inherentemente dispersas (ZONA_CIUADAD_GUATEMALA, TELEFONO_SECUNDARIO). El dato real disponible no disminuyó: se volvió más honesto y granular. El detalle numérico completo está en `data/clean/informe_calidad_antes_despues.csv`.

8. Advertencia sobre tipos de dato al releer el CSV

CSV es texto plano y no conserva el dtype de pandas. Al releer `establecimientos_diversificado_limpio.csv`, las siguientes columnas pueden inferirse erróneamente como numéricas (perdiendo ceros a la izquierda) si no se fuerza el tipo:

```
DTYPE_AL_RELEER = {
    "CODIGO": str,
    "DISTRITO": str,
    "COD_DEPARTAMENTO_ORIGEN": str,
    "ZONA_CIUADAD_GUATEMALA": str,
    "TELEFONO_PRINCIPAL": str,
    "TELEFONO_SECUNDARIO": str,
}
df = pd.read_csv("establecimientos_diversificado_limpio.csv",
dtype=DTYPE_AL_RELEER, encoding="utf-8")
```

Esto **no** es una pérdida de calidad de los datos: es una limitación del formato CSV.